

第十五讲：逼近与回归

凸优化问题的重要应用

杨 林

大 纲

1. 逼近

2. LASSO

大 纲

1. 逼近

2. LASSO

1 逼近

■ 逼近

在凸优化中, 逼近是指一系列解决难以处理的优化问题(如: 问题非凸, 目标函数或约束函数过于复杂)的策略. 其核心思想是: 用一个易于求解的凸优化问题, 去近似一个原本难以求解的问题(或者是通过一个容易获得的次优解, 代替原问题的最优解)

通常采取改变目标函数或约束集, 实现模型简化的效果. 包括四种逼近策略:

- 范数逼近
- 罚函数逼近
- 正则化逼近
- 鲁棒逼近

1.1 范数逼近

$$\text{最小化} \quad \|Ax - b\|$$

($A \in \mathbb{R}^{m \times n}, m \geq n$) Ax 可以表示为 $Ax = x_1 a_1 + \cdots + x_n a_n$,
用 A 的列向量尽可能的逼近或者拟合向量 b

对最优解 $x = \operatorname{argmin}_x \|Ax - b\|$ 的解释:

1. 几何: Ax^* 是 $\mathcal{R}(A)$ 中离 b 最近的点
2. 估计: 线性测量模型

$$y = Ax + v$$

是测量值, x 是未知量, v 是测量误差; 给定 $y = b$, x 的最佳猜测是 x^*

3. 最优设计: x 是设计变量 (输入), x^* 是能最佳逼近期望结果 b 的设计

1.1 范数逼近

最小二乘逼近 ($\|\cdot\|$): 解满足正规方程

$$A^T A x = A^T b$$

$(x^* = (A^T A)^{-1} A^T b, \text{若 } \text{rank } A = n)$

切比雪夫逼近 ($\|\cdot\|_\infty$): 可以作为线性规划问题求解

$$\begin{array}{ll} \text{最小化} & t \\ \text{约束条件} & -t\mathbf{1} \leq Ax - b \leq t\mathbf{1} \end{array}$$

绝对残差和的逼近 ($\|\cdot\|_1$): 可以作为线性规划问题求解

$$\begin{array}{ll} \text{最小化} & \mathbf{1}^T y \\ \text{约束条件} & -y \leq Ax - b \leq y \end{array}$$

1.2 罚函数逼近

$$\begin{array}{ll} \text{最小化} & \phi(r_1) + \cdots + \phi(r_m) \\ \text{约束条件} & r = Ax - b \end{array}$$

$A \in \mathbb{R}^{m \times n}$, $m \geq n$, $\phi: \mathbb{R} \rightarrow \mathbb{R}$ 是一个凸惩罚函数, 残差可代表对回归模型的估计误差

□ 回归分析:

线性拟合 $f(t) = \alpha + \beta t$

每一组输入数据: $\langle x_i, y_i \rangle, i = 1, \dots, m$

每一组数据的残差: $r_i = y_i - (\alpha + \beta x_i)$

优化变量: α, β

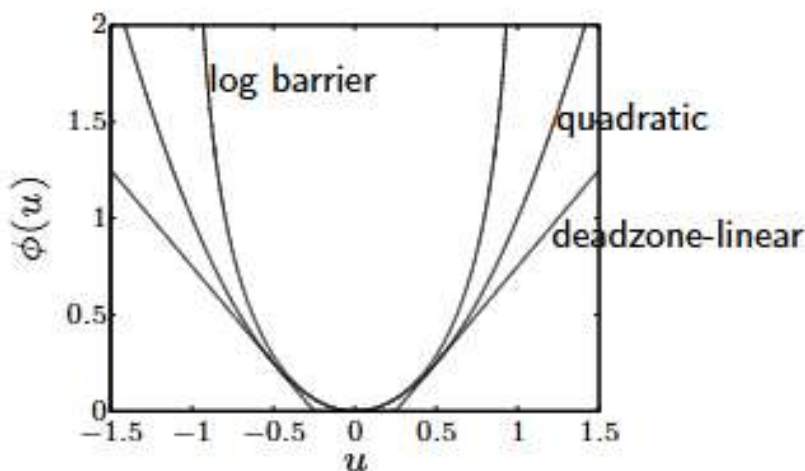
如果线性模型只有 α , ϕ 是二阶范数的平方, 那么优化问题是最小二乘 (方差) 估计

1.2 罚函数逼近

□ 可以使用不同的罚函数形式:

1. 二次函数: $\phi(u) = u^2$
2. 死区-线性宽度为 a : $\phi(u) = \max\{0, |u| - a\}$
3. 对数障碍限制为 a :

$$\phi(u) = \begin{cases} -a^2 \log(1 - (u/a)^2) & |u| < a \\ \infty & \text{其他情况} \end{cases}$$




1.2 罚函数逼近

□ 例 1: ($m = 100, n = 30$): 惩罚的残差直方图

$$\phi(u) = |u|, \phi(u) = u^2,$$

$$\phi(u) = \max\{0, |u| - a\}, \phi(u) = -\log(1 - u^2)$$

罚函数的形状对残差的分布有重大影响





1.2 罚函数逼近

□ Huber 罚函数 (带参数 M), 也叫做鲁棒最小二乘:

$$\phi_{\text{hub}}(u) = \begin{cases} u^2 & |u| \leq M \\ M(2|u| - M) & |u| > M \end{cases}$$

线性增长对于较大的 u 使得逼近对离群值不敏感



左侧: $M = 1$ 时的 Huber 惩罚

右侧: 通过二次(虚线)和 Huber (实线)惩罚拟合 42 个点 t_i, y_i (圆圈)的仿射函数 $f(t) = \alpha + \beta t$

1.3 正则化逼近

■ 正则化

在凸优化中, 正则化是一个修改目标函数的特定技术, 其目的是保证问题的良性态或诱导解具有某种期望的性质

通常是在目标函数中添加一个惩罚项 $R(x)$, 也就是正则化项, 是一个凸函数, 用来惩罚我们不希望看到的解的性质; $\lambda > 0$ 是正则化参数, 用于控制我们对 $R(x)$ 的重视程度

$$\begin{aligned} &\text{最小化(w.r.t. } \mathbb{R}_+^2) \quad (\|Ax - b\|, \|x\|) \\ &\quad (A \in \mathbb{R}^{m \times n}, m \leq n) \end{aligned}$$

1.3 正则化逼近

- 解释:找到良好的逼近解 $Ax \approx b$,且 x 的值较小
- 1. **估计**: 线性测量模型 $y = Ax + v$, 已知 $\|x\|$ 较小
- 2. **最优设计**: x 较小更经济或更高效,或线性模型 $y = Ax$ 仅在 x 较小的情况下有效
- 3. **鲁棒逼近**: x 较小的良好逼近解 $Ax \approx b$ 对 A 带来的误差不敏感,而 x 较大的良好逼近解则敏感

1.3 正则化逼近

■ 标量化逼近因子和正则化项

最小化 $\|Ax - b\| + \gamma\|x\|$

对于不同 $\gamma > 0$, 求解上述问题可以给出最优权衡曲线

Tikhonov 正则化

最小化 $\|Ax - b\|_2^2 + \delta\|x\|_2^2$

可以作为一个最小二乘问题来求解

最小化 $\left\| \begin{bmatrix} A \\ \sqrt{\delta}I \end{bmatrix} x - \begin{bmatrix} b \\ 0 \end{bmatrix} \right\|_2^2$

可以得到解析解为 $x^* = (A^T A + \delta I)^{-1} A^T b$

1.3 正则化逼近

□ 例 2: 最优输入设计

线性时不变系统, 其脉冲响应为 h :

$$y(t) = \sum_{\tau=0}^t h(\tau)u(t-\tau), t = 0, 1, \dots, N$$

输入设计问题: 具有 3 个目标的多元目标问题

跟踪误差与期望输出 y_{des} : $J_{\text{track}} = \sum_{t=0}^N (y(t) - y_{\text{des}}(t))^2$

输入幅度: $J_{\text{mag}} = \sum_{t=0}^N u(t)^2$

输入变化: $J_{\text{der}} = \sum_{t=0}^{N-1} (u(t+1) - u(t))^2$

使用一个微小且缓慢变化的输入信号来跟踪期望输出

1.3 正则化逼近

□ 例 2: 最优输入设计

正则化最小二乘法公式


$$\text{最小化} \quad J_{\text{track}} + \delta J_{\text{der}} + \eta J_{\text{mag}}$$

对于固定的 δ, η , 上述问题也是一个最小二乘问题

1.3 正则化逼近

□ 例 2: 最优输入设计

(顶部) $\delta = 0$, 小 η ; (中间) $\delta = 0$, 大 η ; (底部) 大 δ, η



1.3 正则化逼近

■ 例 3: 信号重建

最小化 (w.r.t. \mathbb{R}_+^2) $(\|\hat{x} - x_{\text{cor}}\|, \phi(\hat{x}))$

$x \in \mathbb{R}^n$ 是未知信号

$x_{\text{cor}} = x + v$ 是(已知)被损坏的 x 版本, 带有加性噪声
变量 \hat{x} (重建信号) 是 x 的估计



$\phi : \mathbb{R}^n \rightarrow \mathbb{R}$ 是正则化函数或平滑目标

示例: 二次平滑, 总变差平滑:




$$\phi_{\text{quad}}(\hat{x}) = \sum_{i=1}^n (\hat{x}_{i+1} - \hat{x}_i)^2, \phi_{\text{tv}}(\hat{x}) = \sum_{i=1}^n |\hat{x}_{i+1} - \hat{x}_i|$$

1.3 正则化逼近

□ 二次平滑示例



original signal x and noisy
signal x_{cor}




three solutions on trade-off curve
 $\|\hat{x} - x_{cor}\|_2$ versus $\phi_{quad}(\hat{x})$

中间达到最优折衷效果：在保持原信号形状前提下滤除毛刺噪声


1.3 正则化逼近

□ 总变差重建示例

二次平滑可以消除信号中的噪声和急剧变化



original signal x and noisy
signal x_{cor}




three solutions on trade-off curve
 $\|\hat{x} - x_{\text{cor}}\|_2$ versus $\phi_{\text{quad}}(\hat{x})$


效果均无法达到最优，二次平滑也会消除信号中的急剧变化

1.3 正则化逼近

□ 总变分平滑保留了信号中的锐利的过渡



original signal x and noisy
signal x_{cor}



three solutions on trade-off curve
 $\|\hat{x} - x_{\text{cor}}\|_2$ versus $\phi_{\text{tv}}(\hat{x})$


1.4 鲁棒逼近

最小化 $\|Ax - b\|$, 其中 A 不确定, 有两种方法:

1. 随机: 假设 A 是随机的, 最小化 $E\|Ax - b\|$
2. 最坏情况 (min-max): 设置 \mathcal{A} 为 A 的可能值, 最小化 $\sup_{A \in \mathcal{A}} \|Ax - b\|$, 仅在特殊情况 (特定的范数 $\|\cdot\|$, 分布, 集合 \mathcal{A}) 下可解

□ 例 4: $A(u) = A_0 + uA_1$

- a. x_{norm} 最小化 $\|A_0x - b\|$
- b. x_{stoch} 最小化 $E\|A(u)x - b\|_2^2$, 其中 u 在 $[-1, 1]$ 上均匀分布
- c. 最小化 $\sup_{-1 \leq u \leq 1} \|A(u)x - b\|_2$ 图示出了 $r(u) = \|A(u)x - b\|_2$



1.4 鲁棒逼近

随机鲁棒 LS, 其中 $A = \bar{A} + U$, U 随机, $\mathbf{E}U = 0$, $\mathbf{E}U^T U = P$

$$\text{最小化 } \mathbf{E}\|(\bar{A} + U)x - b\|_2^2$$

1. 目标函数的显式表达式:

$$\begin{aligned}\mathbf{E}\|Ax - b\|_2^2 &= \mathbf{E}\|\bar{A}x - b + Ux\|_2^2 \\ &= \|\bar{A}x - b\|_2^2 + \mathbf{E}x^T U^T U x = \|\bar{A}x - b\|_2^2 + x^T P x\end{aligned}$$

2. 因此, 鲁棒最小二乘问题等价于如下最小二乘问题

$$\text{最小化 } \|\bar{A}x - b\|_2^2 + \|P^{1/2}x\|_2^2$$

3. 当 $P = \delta I$ 时, 得到 Tikhonov 正则化问题

$$\text{最小化 } \|\bar{A}x - b\|_2^2 + \delta\|x\|_2^2$$

1.4 鲁棒逼近*

■ 最坏情况鲁棒 LS

满足 $A = \{\bar{A} + u_1 A_1 + \cdots + u_p A_p \mid \|u\|_2 \leq 1\}$

$$\text{最小化 } \sup_{A \in \mathcal{A}} \|\bar{A}x - b\|_2^2 = \sup_{\|u\|_2 \leq 1} \|P(x)u + q(x)\|_2^2$$

其中 $P(x) = [A_1 x, A_2 x, \cdots, A_p x]$, $q(x) = \bar{A}x - b$

1. 以下问题之间存在强对偶性

$$\begin{array}{ll} \text{最大化} & \|P(x)u + q(x)\|_2^2 \\ \text{约束条件} & \|u\|_2^2 \leq 1 \end{array}$$

$$\begin{array}{ll} \text{最小化} & t + \lambda \\ \text{约束条件} & \begin{bmatrix} I & P & q \\ P^T & \lambda I & 0 \\ q(x)^T & 0 & t \end{bmatrix} \succeq 0 \end{array}$$

1.4 鲁棒逼近*

2. 因此, 鲁棒 LS 问题是等价于 SDP


$$\begin{array}{ll} \text{最小化} & t + \lambda \\ \text{约束条件} & \begin{bmatrix} I & P(x) & q(x) \\ P(x)^T & \lambda I & 0 \\ q(x)^T & 0 & t \end{bmatrix} \succeq 0 \end{array}$$

1.4 鲁棒逼近*

□ 例 5:

$$r(u) = \|(A_0 + u_1 A_1 + u_2 A_2)x - b\|_2$$

其中 u 在单位圆上均匀分布, 对于 x 的三个值 (最坏情况鲁棒LS)



大 纲

1. 逼近

2. LASSO

2 LASSO

线性回归问题中, 通过最小二乘法拟合, 特征数量远大于样本数量时, 容易过拟合, 需要从众多特征中识别少数关键特征

$$\text{最小化 } \sum_{i=1}^n (y_i - \beta_0 - \sum_j x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p \|\beta_j\|$$

岭回归 (Ridge Regression, 1970s)

$$\text{最小化 } \sum_{i=1}^n (y_i - \beta_0 - \sum_j x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p \beta_j^2$$

等价于在最小二乘的基础上, 加上约束 “ $\sum \beta_j^2 \leq s$ ”
约束模型复杂度, 但不能产生稀疏解

2 LASSO

Robert Tibshirani于1996年发表奠基性论文：

Regression Shrinkage and Selection via the Lasso (Journal of the Royal Statistical Society, Series B)


Lasso (Least Absolute Shrinkage and Selection Operator)
是一种结合了特征选择和正则化的线性回归方法

$$\text{最小化 } \sum_{i=1}^n (y_i - \beta_0 - \sum_j x_{ij} \beta_j)^2 + \lambda \sum_{j=1}^p |\beta_j|$$


等价于在最小二乘的基础上，加上约束 “ $\sum |\beta_j| \leq s$ ”，
LASSO 在降低模型复杂度的基础上，实现了特征选择

LASSO的提出是统计学和机器学习的重要转折点，它将变量选择从离散的组合优化问题转化为连续的凸优化问题，开辟了稀疏建模的新时代，其影响力超越统计学，延伸到信号处理、计量经济学、生物信息学等多个领域

2 LASSO




Lasso



Ridge Regression

2 LASSO



-- Statistical Learning with Sparsity by Hastie, Tibshirani & Wainwright

谢谢！